# 1. 在 Tiny-ImageNet 数据集上训练 Resnet 模型

### 1. 计算图片经过各层处理后的中间结果的大小

- 1. 输入层: 输入的图像大小是 64x64x3。
- 2. 第一层(Conv1): 采用7x7的卷积核,步长为2,然后是最大池化层,步长为2和3x3的卷积核,输出的大小是 16x16x64。
- 3. 第二层(Conv2\_x): 这是ResNet的第一个构建块,包含2个3x3的卷积层,输出的大小还是16x16x64。
- 4. 第三层(Conv3\_x): 这是ResNet的第二个构建块,包含2个3x3的卷积层,但是这里步长为2,并将特征图的深度翻倍,输出的大小是8x8x128。
- 5. 第四层(Conv4\_x): 这是ResNet的第三个构建块,包含2个3x3的卷积层,步长为2,并将特征图的深度翻倍,输出的大小是 4x4x256。
- 6. 第五层(Conv5\_x): 这是ResNet的第四个构建块,包含2个3x3的卷积层,步长为2,并将特征图的深度翻倍,输出的大小是2x2x512。
- 7. 平均池化层: 这个层会将每个特征图降维到1x1, 所以输出的大小是 1x1x512。
- 8. 全连接层(FC): 因为Tiny-ImageNet有200个类别,所以这一层的大小就是1x1x200。

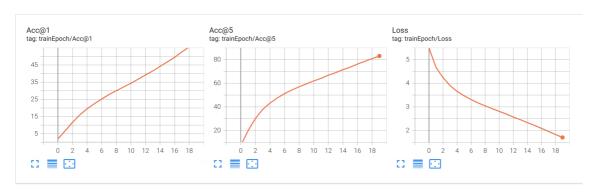
### 2. 改动示例中的源代码

1. 我们首先要将ImageNet改成200维,这个改动很简单,我们只需要加入如下的代码:

```
#Change the dim of image input
num_ftrs = model.fc.in_features
model.fc = nn.Linear(num_ftrs,200)
```

#### 我们将最后的输出层改为200即可

- 2. 然后,我们需要改变原来的数据集,这一部分我们使用 wnids.txt 和 val/val\_annotations.txt 来重新修订每个样本的标签。但是我们发现在bitahub上的数据集已 经将这一工作完成,所以我们为了避免本地上传数据的不便,我们在征得助教同意后直接使用 bitahub上的数据集。需要注意的是,我们也完成了这一部分代码的工作,放在文件classify.py中,并且我们将改变的文件放在latest.patch中,并且我们的每个改动都加入了注释
- 3. 如上所述,我们在代码中加入tensorboard的相关代码即可
- 4. 我们将训练的epoch设为20, 我们观察他的图像变化, 我们发现



- 训练损失(Training Loss)曲线:它随着训练轮次(epoch)的增加而稳定下降。开始时,模型是随机初始化的,所以应该是很高的。随着模型学习训练数据,损失逐渐下降。并且我们的Loss大体上是单调的,说明并没有出现过拟合的情况
- 。 训练精度 (Training Accuracy) 曲线:它随着训练轮次 (epoch) 的增加而稳定上升。并且在 18个epoch后接受概率达到了90%,我们再训练多个epoch后即可达到95%
- o 验证损失 (Validation Loss) 曲线: 他随着epoch的增加而增加,这是因为模型在训练数据上的性能提高,导致验证数据上的损失下降。并且我们发现没有出现过拟合的情况
- 验证精度(Validation Accuracy)曲线:我们发现他先上升到最后有轻微的下降,这是因为模型在训练数据上的性能提高,导致验证数据上的精度提高。

## 3. 分别在无GPU、1个GPU、多个GPU环境下训练,比较速度差异

- 1. 我们使用bitahub平台,分别使用无GPU,一个GPU(1080Ti)和八个GPU(1080Ti)进行训练
- 2. 我们发现在训练同样的内容中(20个epoch)中,无GPU用时36h37min23s,一个GPU训练时间需要1h39min30s,而八个GPU训练时间只需要57min30s
- 3. 所以我们可以计算出训练一个epoch,无GPU需要110min,一个GPU需要4.95min,而八个GPU仅需要2.85min

#### 4. 对比两次评估的差异

- 1. 我们首先改变main.py中的函数,使得我们在每一次epoch后都可以保存相应的模型
- 2. 我们决定选取第7回和第18回的两个数据进行分析,我们发现他们在test阶段的接受率如下:

```
Test: [ 1/40] Time 3.417 ( 3.417) Loss 2.1413e+00 (2.1413e+00)
Acc@1 43.75 (43.75) Acc@5 77.34 (77.34)
Test: [11/40] Time 0.074 (0.739) Loss 2.3901e+00 (2.3964e+00)
Acc@1 47.27 (40.91) Acc@5 67.58 (70.63)
Test: [21/40] Time 3.098 (0.761) Loss 2.6638e+00 (2.5990e+00)
Acc@1 34.77 (37.30) Acc@5 66.80 (66.59)
Test: [31/40] Time 0.058 (0.744) Loss 2.9175e+00 (2.6584e+00)
Acc@1 33.20 (36.71) Acc@5 59.77 (65.30)
    Acc@1 37.940 Acc@5 66.380
Test: [ 1/40] Time 3.491 ( 3.491) Loss 1.8144e+00 (1.8144e+00)
Acc@1 54.30 (54.30) Acc@5 82.81 (82.81)
Test: [11/40] Time 0.081 (0.795) Loss 2.0316e+00 (1.8120e+00)
Acc@1 50.78 (53.80) Acc@5 77.34 (81.39)
Test: [21/40] Time 2.070 (0.731) Loss 2.2055e+00 (2.0703e+00)
Acc@1 50.00 (49.87) Acc@5 70.70 (76.21)
Test: [31/40] Time 0.056 (0.654) Loss 2.6972e+00 (2.1681e+00)
Acc@1 39.06 (48.61) Acc@5 68.36 (74.72)
 * Acc@1 48.730 Acc@5 75.300
```

我们发现他们的TOP5的接受率差别并不是很大,但是他们对每个图像的判断是否也相似呢? 我们设计了一个evaluate.py函数找出这两个模型不同的判断 我们发现

```
val_1008.JPEG 107
val_132.JPEG 158
val_5261.JPEG 139
val_1051.JPEG 90
val_3121.JPEG 138
val_2321.JPEG 67
val_1764.JPEG 135
val_1983.JPEG 198
val_1344.JPEG 38
val_1314.JPEG 88
```

这几个图片判断不同

日志

# 2. 复现Word-levelLanguageModel并讨论

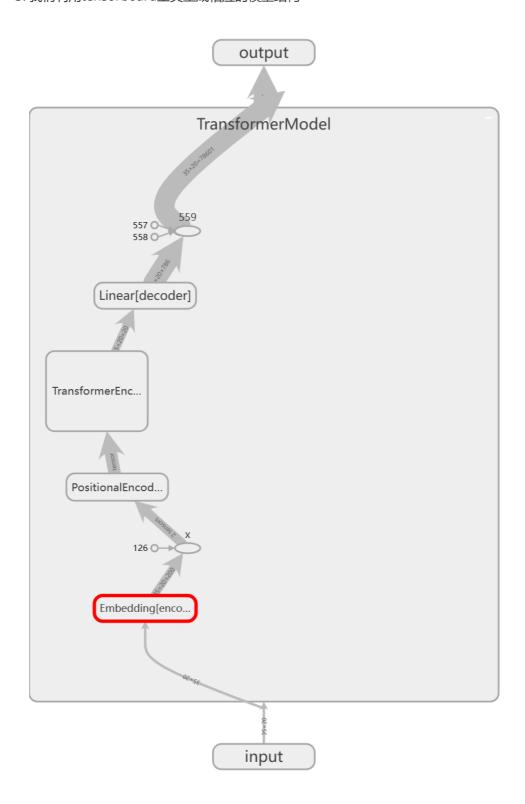
1. 我们按照提供的代码及其要求,首先训练六个epoch,并且生成模型

```
| epoch 5 | 2600/ 2983 batches | Ir 5.00 | ms/batch 14.67 | loss 4.98 | ppl 145.68 | epoch 5 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.71 | loss 4.92 | ppl 136.51 | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | |
| end of epoch 5 | time: 44.58s | valid loss 5.37 | valid ppl 214.11 |
| epoch 6 | 200/ 2983 batches | Ir 5.00 | ms/batch 16.02 | loss 4.95 | ppl 141.12 | epoch 6 | 400/ 2983 batches | Ir 5.00 | ms/batch 14.66 | loss 4.96 | ppl 143.27 | epoch 6 | 600/ 2983 batches | Ir 5.00 | ms/batch 14.47 | loss 4.79 | ppl 120.27 | epoch 6 | 800/ 2983 batches | Ir 5.00 | ms/batch 14.47 | loss 4.79 | ppl 127.26 | epoch 6 | 1000/ 2983 batches | Ir 5.00 | ms/batch 14.459 | loss 4.81 | ppl 127.06 | epoch 6 | 1200/ 2983 batches | Ir 5.00 | ms/batch 14.59 | loss 4.87 | ppl 127.06 | epoch 6 | 1200/ 2983 batches | Ir 5.00 | ms/batch 14.59 | loss 4.87 | ppl 129.70 | epoch 6 | 1400/ 2983 batches | Ir 5.00 | ms/batch 14.59 | loss 4.87 | ppl 129.70 | epoch 6 | 1600/ 2983 batches | Ir 5.00 | ms/batch 14.52 | loss 4.86 | ppl 142.97 | epoch 6 | 1800/ 2983 batches | Ir 5.00 | ms/batch 14.52 | loss 4.86 | ppl 129.33 | epoch 6 | 2000/ 2983 batches | Ir 5.00 | ms/batch 14.68 | loss 4.79 | ppl 134.86 | epoch 6 | 2200/ 2983 batches | Ir 5.00 | ms/batch 14.85 | loss 4.90 | ppl 134.86 | epoch 6 | 2400/ 2983 batches | Ir 5.00 | ms/batch 14.68 | loss 4.90 | ppl 130.22 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.68 | loss 4.81 | ppl 120.55 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.68 | loss 4.81 | ppl 120.22 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.69 | loss 4.81 | ppl 120.23 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.69 | loss 4.81 | ppl 120.22 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.69 | loss 4.81 | ppl 120.22 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.69 | loss 4.81 | ppl 120.23 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.69 | loss 4.81 | ppl 120.22 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | ms/batch 14.60 | epoch 6 | 2800/ 2983 batches | Ir 5.00 | epoch 6 |
```

2. 我们使用生成的模型进行训练,得出相应的生成文本generated.txt

generated.txt

```
1 Center ) , a car was questioned by his . Despite that drivers died they moved down the west ,
2 legitimately and is a lovely based on the Maori and Injected Dreams ( August ) were Ishmael , Andy 766th
3 Regiment , the Royal Society in 1929 ) . - ecos- cunbs( 1993 - 2080 9) . and a
4 ejaculation was described by Suez , in 1913 - 1918 , many of St John Madison in - univolation | Madison | Madi
```



#### CNN和Transfermer在捕捉上下文依赖上的差异

1. **序列长度限制**: CNN由于其局部感受野的设计,最多只能捕捉到有限的上下文信息,这个长度 通常取决于卷积核的大小和层数。虽然有一些技巧(如扩大卷积核的大小或者使用Dilated Convolution)可以提升CNN对更长序列的感知能力,但它依然有其固有的局限性。然而, Transformer模型能够处理任意长度的序列,并且在任意两个序列位置之间都能建立直接的依赖关系。

- 2. **并行计算**: CNN由于其卷积操作的特性,可以很好地进行并行化处理,这使得它在处理长序列时相比RNN等模型有很大的速度优势。但是Transformer模型由于其全局自注意力(selfattention)机制,计算复杂度和存储复杂度与输入序列的长度平方成正比,使得处理极长的序列时可能面临计算和存储压力。
- 3. **上下文依赖建模方式**: CNN通过连续的卷积层来建立更长的上下文依赖,也就是说,高层的卷积核可以看到底层卷积核的输出,从而间接地看到更长的输入序列范围。然而这种方式建立的依赖性是间接的,可能无法很好地处理一些复杂的长距离依赖问题。而Transformer的自注意力机制,可以使得任意两个序列位置直接建立连接,更好地处理长距离依赖问题。
- 4. **处理语义角色关系**:对于某些任务(如机器翻译),可能需要理解句子中的词语之间的关系,特别是语义角色关系,比如主谓宾结构等。由于Transformer的全局自注意力机制,能够更好地处理这种语义关系,而CNN可能在这方面的表现较差。